PROYECTO-FASE III: SEGMENTACIÓN DE IMÁGENES

Francisco Javier López Olvera
Alan Artemio Quero Alavez
Wendy Krystal Rodríguez Aguilar

Dra. Verónica Rodríguez López

4 de mayo de 2026

Contenido

- 1) Detector de bordes de Canny
- 2) Umbralización de Otsu: un umbral
- 3) Umbralización de Otsu: dos umbrales
- 4)K-Means usando la información en RGB
- 5) K-Means usando la información en otro modelo de color distinto a RGB y más apropiado para segmentar las imágenes
- 6) Patrones binarios locales (LPB) usando los LPB de regiones de interés como fuego, humo, vegetación

Objetivo de la Fase III

El objetivo de esta fase es implementar técnicas de segmentación para identificar regiones relevantes en imágenes del conjunto *foresFireDataset(ObjectDetection)*.

- Separar regiones asociadas a fuego, humo y vegetación.
- Comparar métodos basados en bordes, umbrales, color y textura.
- Evaluar los resultados en imágenes con diferente nivel de complejidad.

Metodología General

Para cada imagen del conjunto de datos se siguió el siguiente procedimiento:

1. Lectura de la imagen.
2. Preprocesamiento o cambio de modelo de color.
3. Aplicación de la técnica de segmentación seleccionada.
4. Ajuste de parámetros del método.
5. Obtención de la máscara o imagen segmentada.
6. Comparación visual de resultados.
7. Organización de resultados en tablas y figuras.

Diagrama de Flujo General

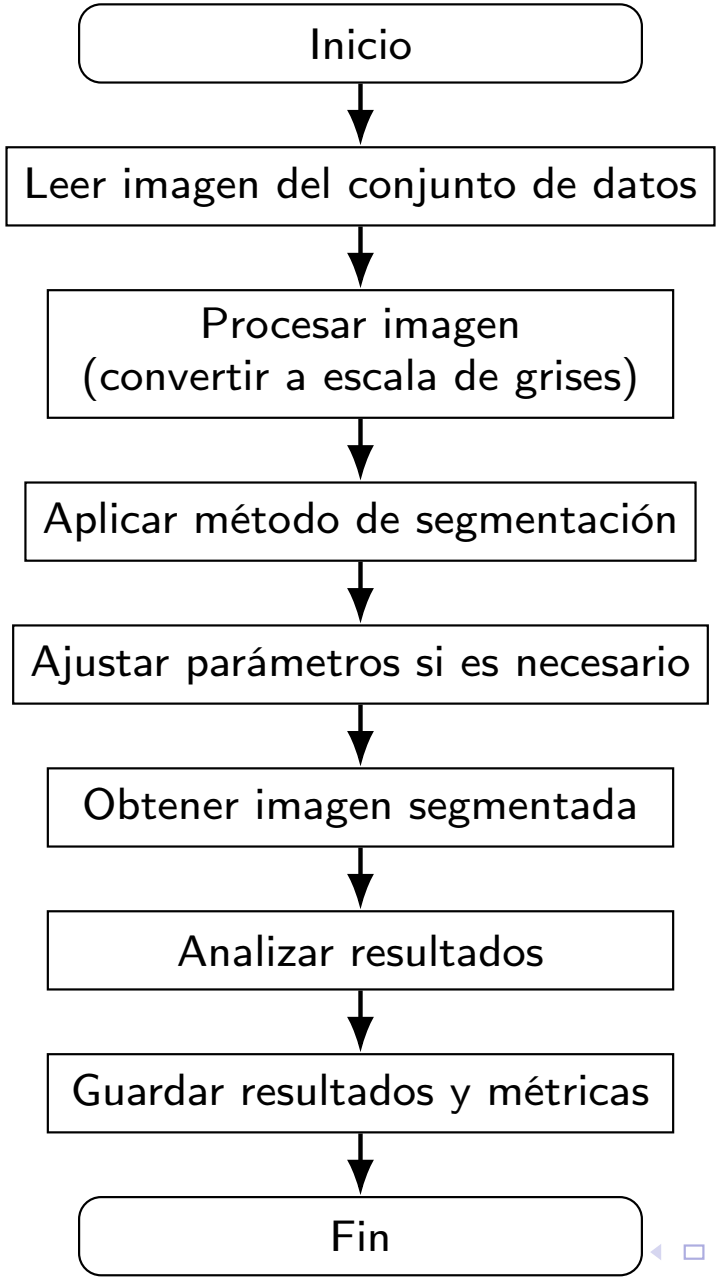

Imágenes originales

Fácil

F1

Medio

M1

Difícil

D1

F2

M2

D2

Detector de Bordes de Canny

El detector de Canny identifica bordes mediante gradiente, supresión de no máximos e histéresis de umbral.

$$|\nabla f| = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2}$$

$$\alpha(x, y) = \tan^{-1}\left(\frac{\frac{\partial f(x,y)}{\partial x}}{\frac{\partial f(x,y)}{\partial y}}\right)$$

- Primero se suaviza la imagen con un filtro Gaussiano.
- Después se calcula magnitud y dirección del gradiente.
- Finalmente se aplican supresión de no máximos e histéresis.

Diagrama de Flujo: Detector de Bordes de Canny

Inicio

↓

Leer imagen

↓

Suavizar con filtro Gaussiano

↓

Obtener el gradiente

$$\nabla f(x,y) = [\frac{\partial f(x,y)}{\partial x}, \frac{\partial f(x,y)}{\partial y}]$$

↓

Calcular la magnitud del gradiente

$$Mag(\nabla f(x,y)) = \sqrt{(\frac{\partial f(x,y)}{\partial x})^2 + (\frac{\partial f(x,y)}{\partial y})^2}$$

↓

Calcular dirección del gradiente

$$Dir(\nabla f(x,y)) = arctan\left(\frac{\partial f(x,y)/\partial y}{\partial f(x,y)/\partial x}\right)$$

↓

Supresión de no máximos

↓

Histéresis de umbral

↓

Salida: bordes

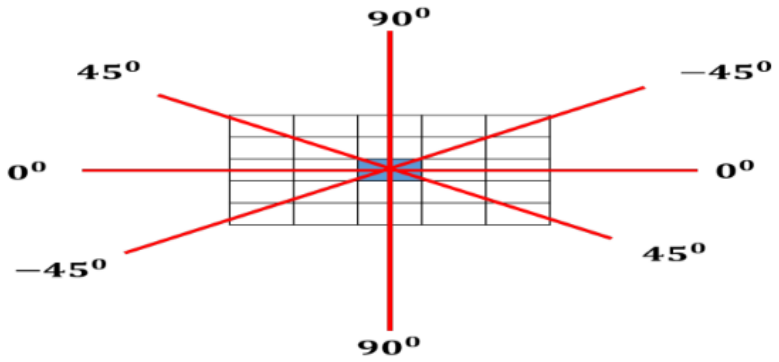

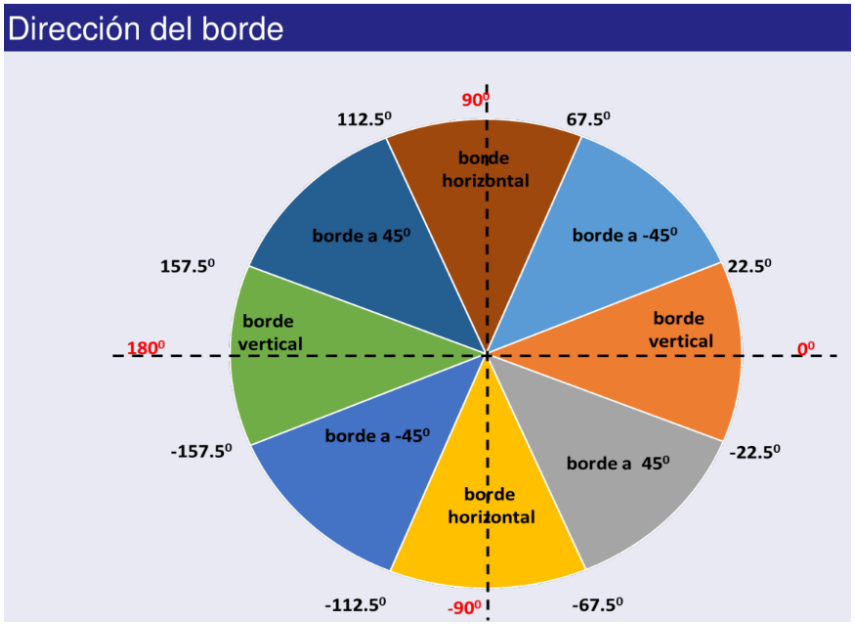

Resultados de Detector de Bordes de Canny

Fácil | **Medio** | **Difícil**

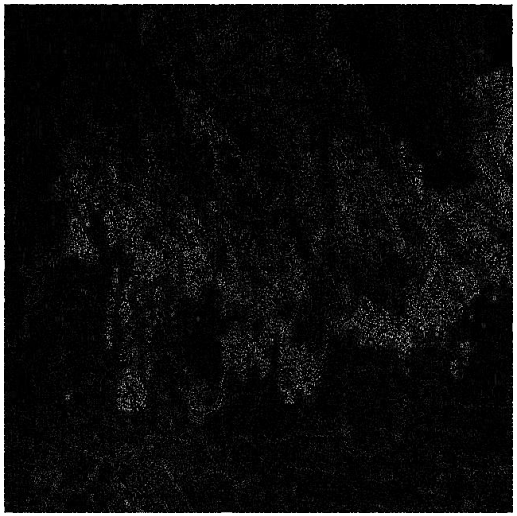

F1

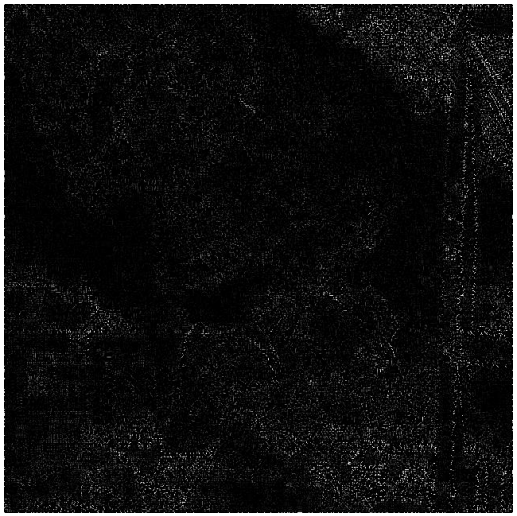

M1

D1

F2

M2

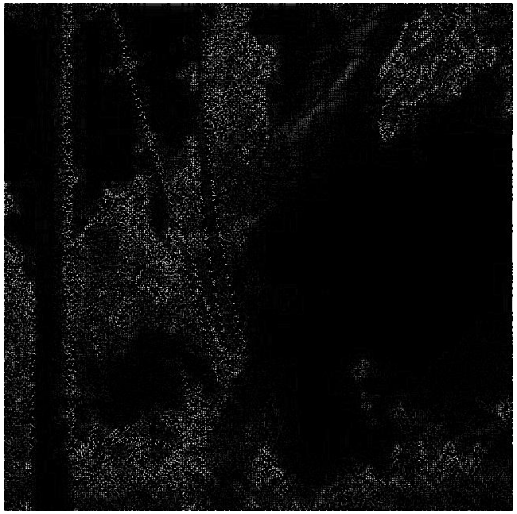

D2

Umbralización de Otsu: un umbral

El método de Otsu determina automáticamente el umbral óptimo a partir del histograma de la imagen.

1. Calcular el histograma normalizado: $p_i, \quad i = 0, 1, \ldots, L-1$
2. Calcular probabilidad acumulada, media acumulada y media global:

$$P_1(k) = \sum_{i=0}^{k} p_i \qquad m(k) = \sum_{i=0}^{k} i\, p_i \qquad m_G = \sum_{i=0}^{L-1} i\, p_i$$

3. Evaluar la varianza entre clases:

$$\sigma_B^2(k) = \frac{[m_G P_1(k) - m(k)]^2}{P_1(k)\,[1 - P_1(k)]}$$

4. Obtener el umbral óptimo K*, como el valor de k que maximiza $\sigma_B(k)$ Si no es único obtener el promedio de los k.
5. Obtener la imagen segmentada:

$$g(x,y) = \begin{cases} 1, & f(x,y) \leq K^* \\ 0, & \text{en otro caso} \end{cases}$$

Diagrama de Flujo: Umbralización de Otsu simple

Inicio

↓

Leer imagen $f(x, y)$

↓

Calcular histograma normalizado

$$p_i, \quad i = 0, 1, \ldots, L-1$$

↓

Calcular acumuladas y media global

$$P_1(k) = \sum_{i=0}^{k} p_i, \quad m(k) = \sum_{i=0}^{k} i\, p_i, \quad m_G = \sum_{i=0}^{L-1} i\, p_i$$

↓

Calcular varianza entre clases

$$\sigma_B^2(k) = \frac{[m_G P_1(k) - m(k)]^2}{P_1(k)[1 - P_1(k)]}$$

↓

Obtener umbral óptimo

$$K^* = \arg\max_k \sigma_B^2(k)$$

↓

Segmentar imagen

$$g(x, y) = \begin{cases} 1, & f(x, y) \leq K^* \\ 0, & \text{en otro caso} \end{cases}$$

↓

Salida: imagen segmentada

Resultados de Umbralización de Otsu: un umbral

Fácil **Medio** **Difícil**

F1

M1

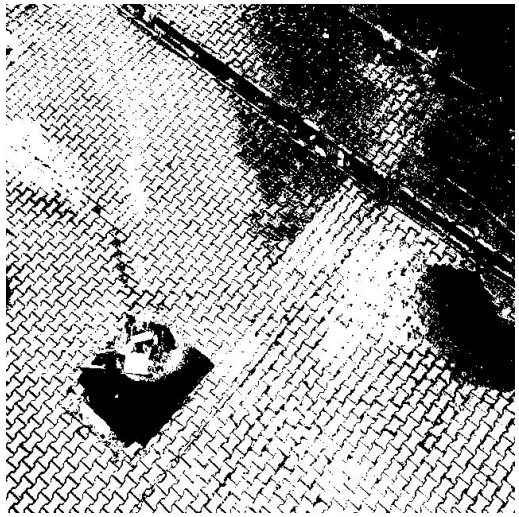

D1

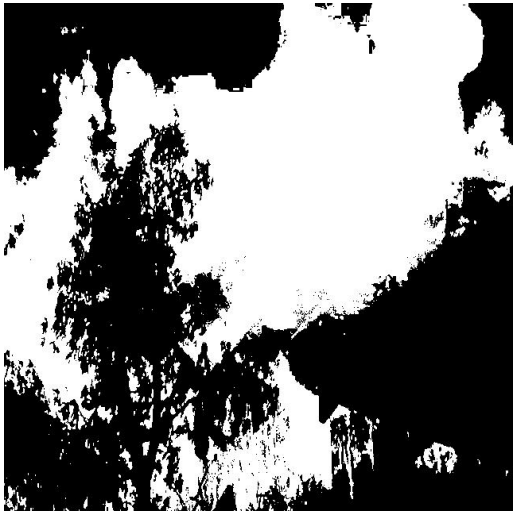

F2

M2

D2

Umbralización de Otsu: dos umbrales

La umbralizacion múltiple sólo es recomendable para cuando se tienen tres tipos de regiones (tres clases de píxeles), separadas por dos umbrales K_1^* y K_2^*.

$$g(x,y) = \begin{cases} 0, & f(x,y) \leq K_1^* \\ 127, & K_1^* < f(x,y) \leq K_2^* \\ 255, & f(x,y) > K_2^* \end{cases}$$

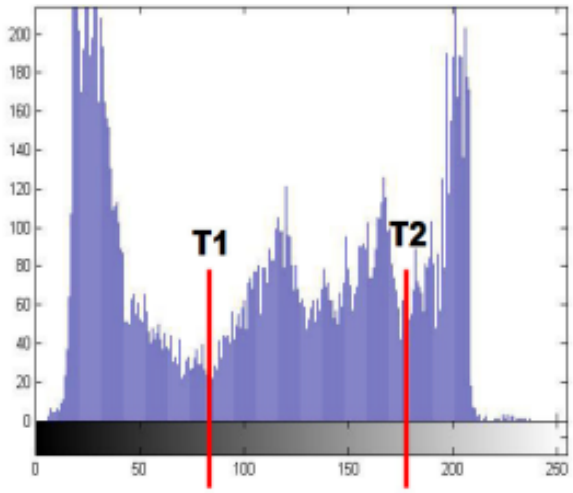

- Busca los dos umbrales que separen mejor las regiones de la imagen.
- Cada clase representa un rango diferente de intensidades.
- Es útil cuando existen tres zonas principales, por ejemplo: fondo, humo y fuego.
- A diferencia de Otsu con un umbral, permite una segmentación más detallada.

Diagrama de Flujo: Umbralización múltiple de Otsu

Inicio

Calcular histograma normalizado
$p_i, \quad i = 0, 1, \ldots, L-1$

Calcular media global: $m_G = \sum_{i=0}^{L-1} i\, p_i$

Calcular probabilidades: $P_1 = \sum_{i=0}^{K_1} p_i, \; P_2 = \sum_{i=K_1+1}^{K_2} p_i, \; P_3 = \sum_{i=K_2+1}^{L-1} p_i$

Calcular medias de clase: $m_1 = \frac{1}{P_1} \sum_{i=0}^{K_1} i\, p_i, \; m_2 = \frac{1}{P_2} \sum_{i=K_1+1}^{K_2} i\, p_i, \; m_3 = \frac{1}{P_3} \sum_{i=K_2+1}^{L-1} i\, p_i$

Calcular varianza entre clases
$\sigma_B^2(K_1, K_2) = P_1(m_1 - m_G)^2 + P_2(m_2 - m_G)^2 + P_3(m_3 - m_G)^2$

Obtener umbrales óptimos

Imagen segmentada: $g(x,y) = \begin{cases} 0, & f(x,y) \leq K_1^* \\ 127, & K_1^* < f(x,y) \leq K_2^* \\ 255, & f(x,y) > K_2^* \end{cases}$

Resultados de Umbralización de Otsu: dos umbrales

Fácil | **Medio** | **Difícil**

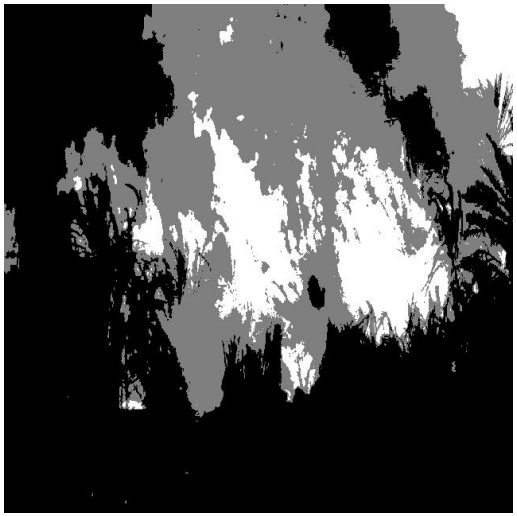

F1

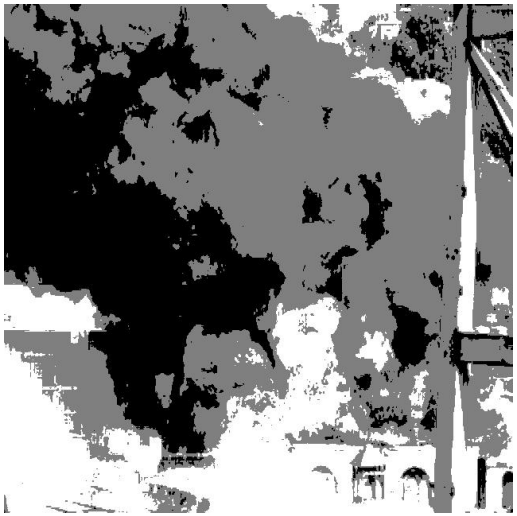

M1

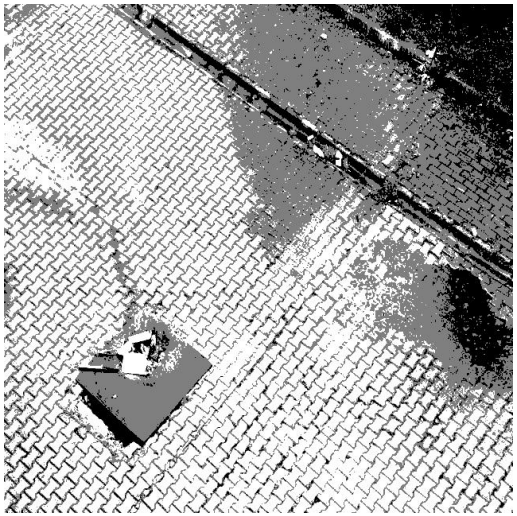

D1

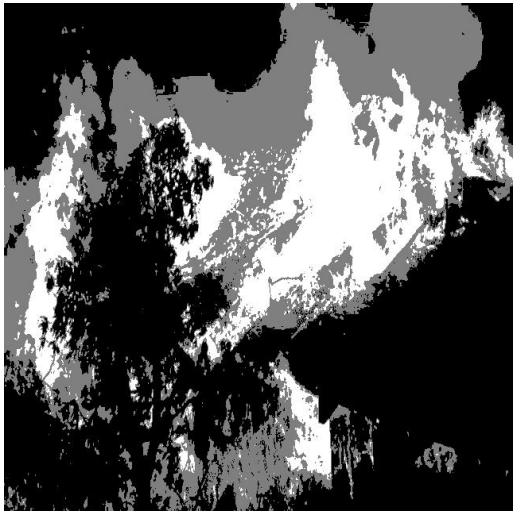

F2

M2

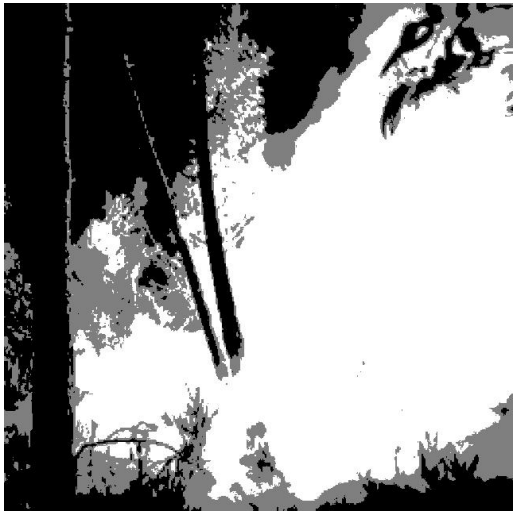

D2

K-Means usando la información en RGB

K-Means es un método de agrupamiento no supervisado que segmenta la imagen agrupando píxeles con características de color similares.
En este caso, cada píxel se representa como un vector en el espacio RGB:

$$X_i = [R_i,\ G_i,\ B_i]$$

El algoritmo busca dividir los datos en K grupos minimizando la distancia entre cada píxel y el centroide de su grupo.

$$J = \sum_{k=1}^{K} \sum_{X_i \in C_k} \|X_i - \mu_k\|^2$$

- Cada píxel se clasifica según sus valores de rojo, verde y azul.
- Los centroides se actualizan iterativamente hasta converger.
- En este proyecto se utilizaron $K = 4$ grupos.
- El resultado es una imagen segmentada por similitud de color.

Diagrama de Flujo: K-Means en RGB

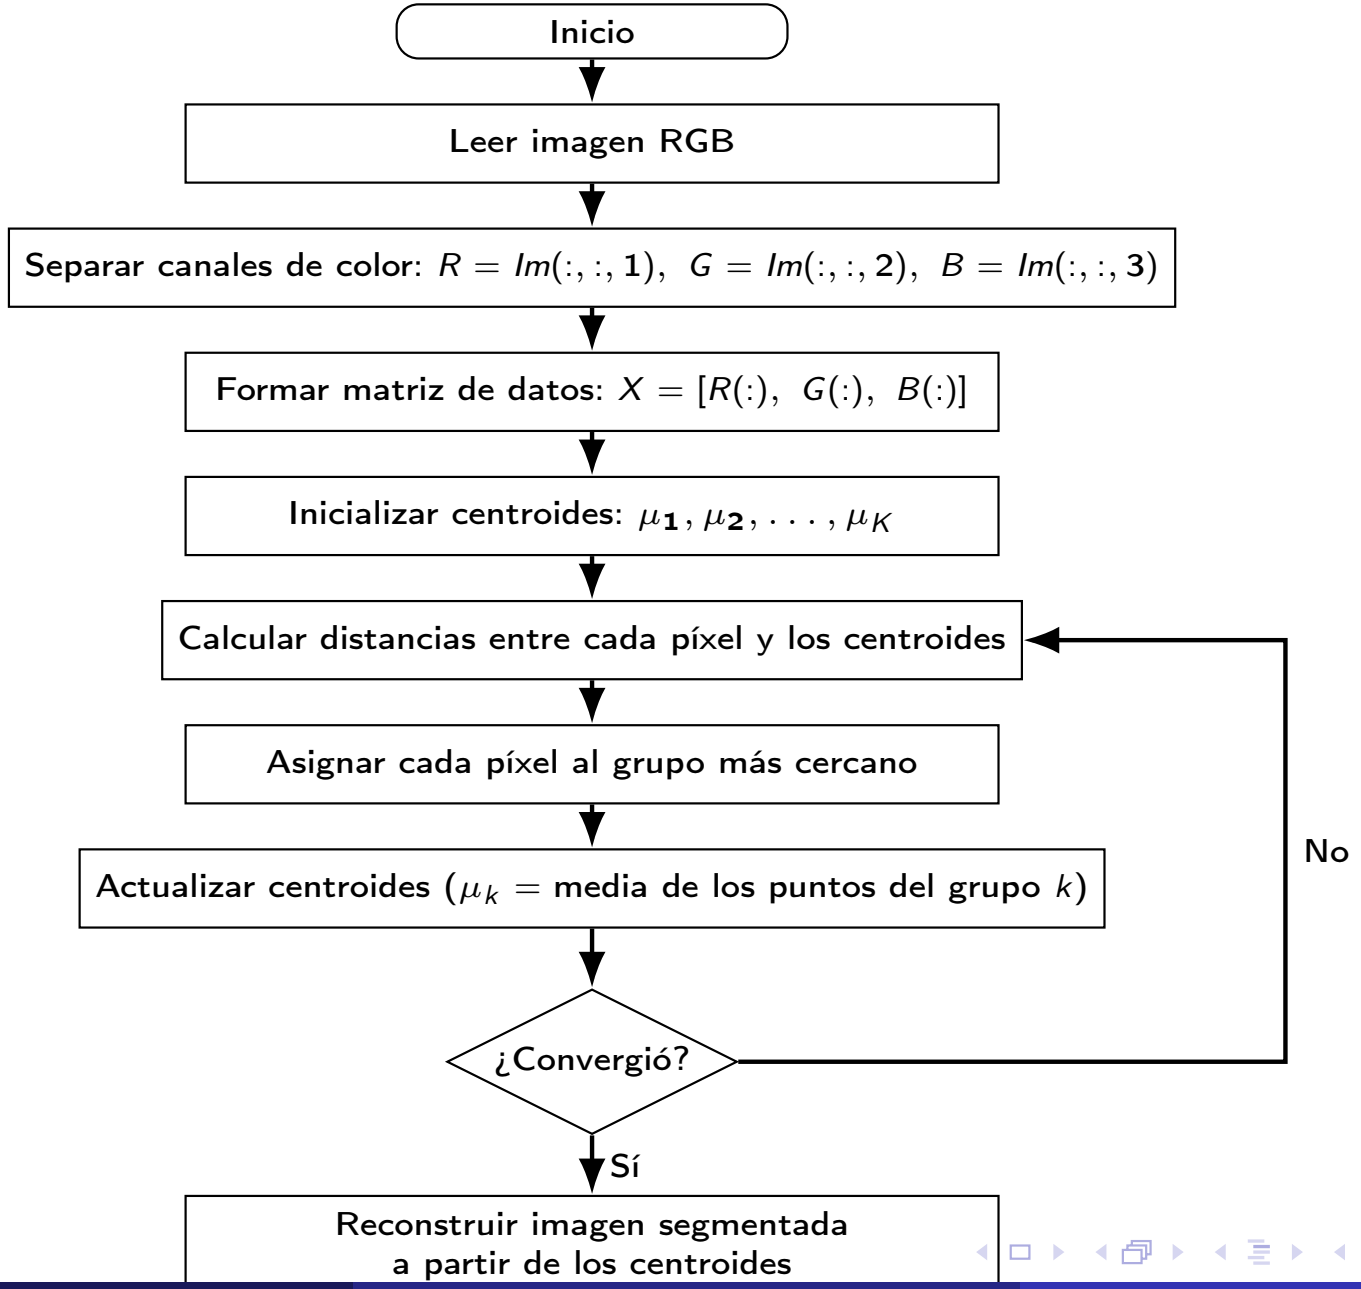

Resultados de K-Means usando la información en RGB

Fácil

F1

Medio

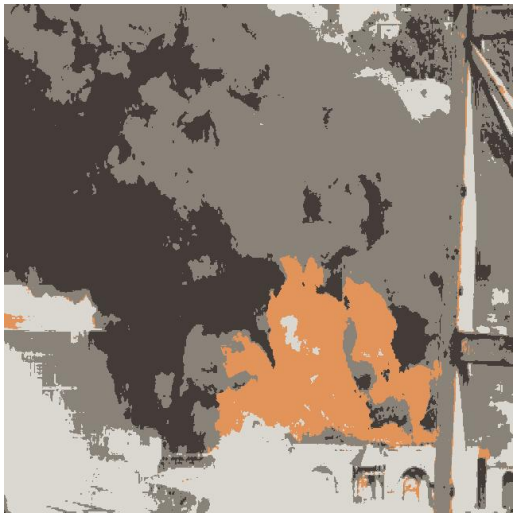

M1

Difícil

D1

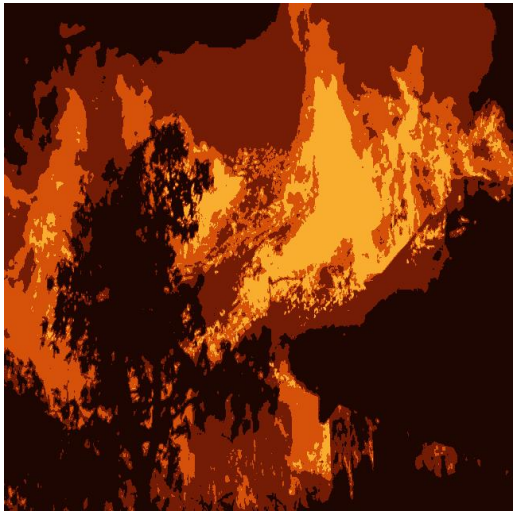

F2

M2

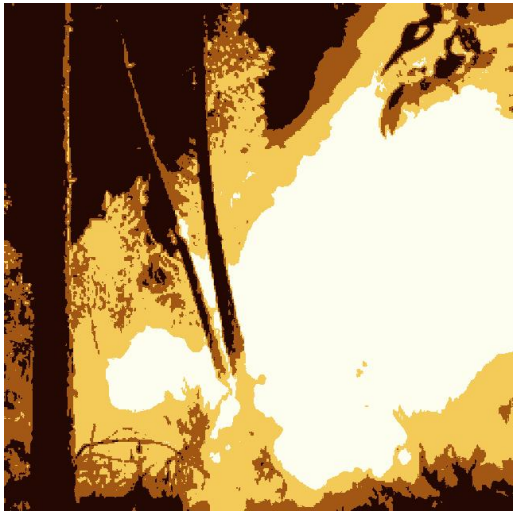

D2

K-Means en otro modelo de color: CIE L*a*b*

Para mejorar la segmentación por color, la imagen se transforma del espacio RGB al espacio **CIE L*a*b***, el cual separa la luminancia de la información cromática.
En este caso, cada píxel se representa usando únicamente los canales cromáticos $X_i = [a_i^*, b_i^*]$.

El algoritmo K-Means agrupa los píxeles en K clases minimizando la distancia entre cada píxel y el centroide de su grupo.

$$J = \sum_{k=1}^{K} \sum_{X_i \in C_k} \|X_i - \mu_k\|^2$$

- L^* representa la luminancia.
- a^* y b^* describen la información de color.
- En este proyecto se emplean los canales a^* y b^* para segmentar por similitud cromática.
- Finalmente, la imagen segmentada se visualiza nuevamente en RGB.

Diagrama de Flujo: K-Means en CIE L*a*b*

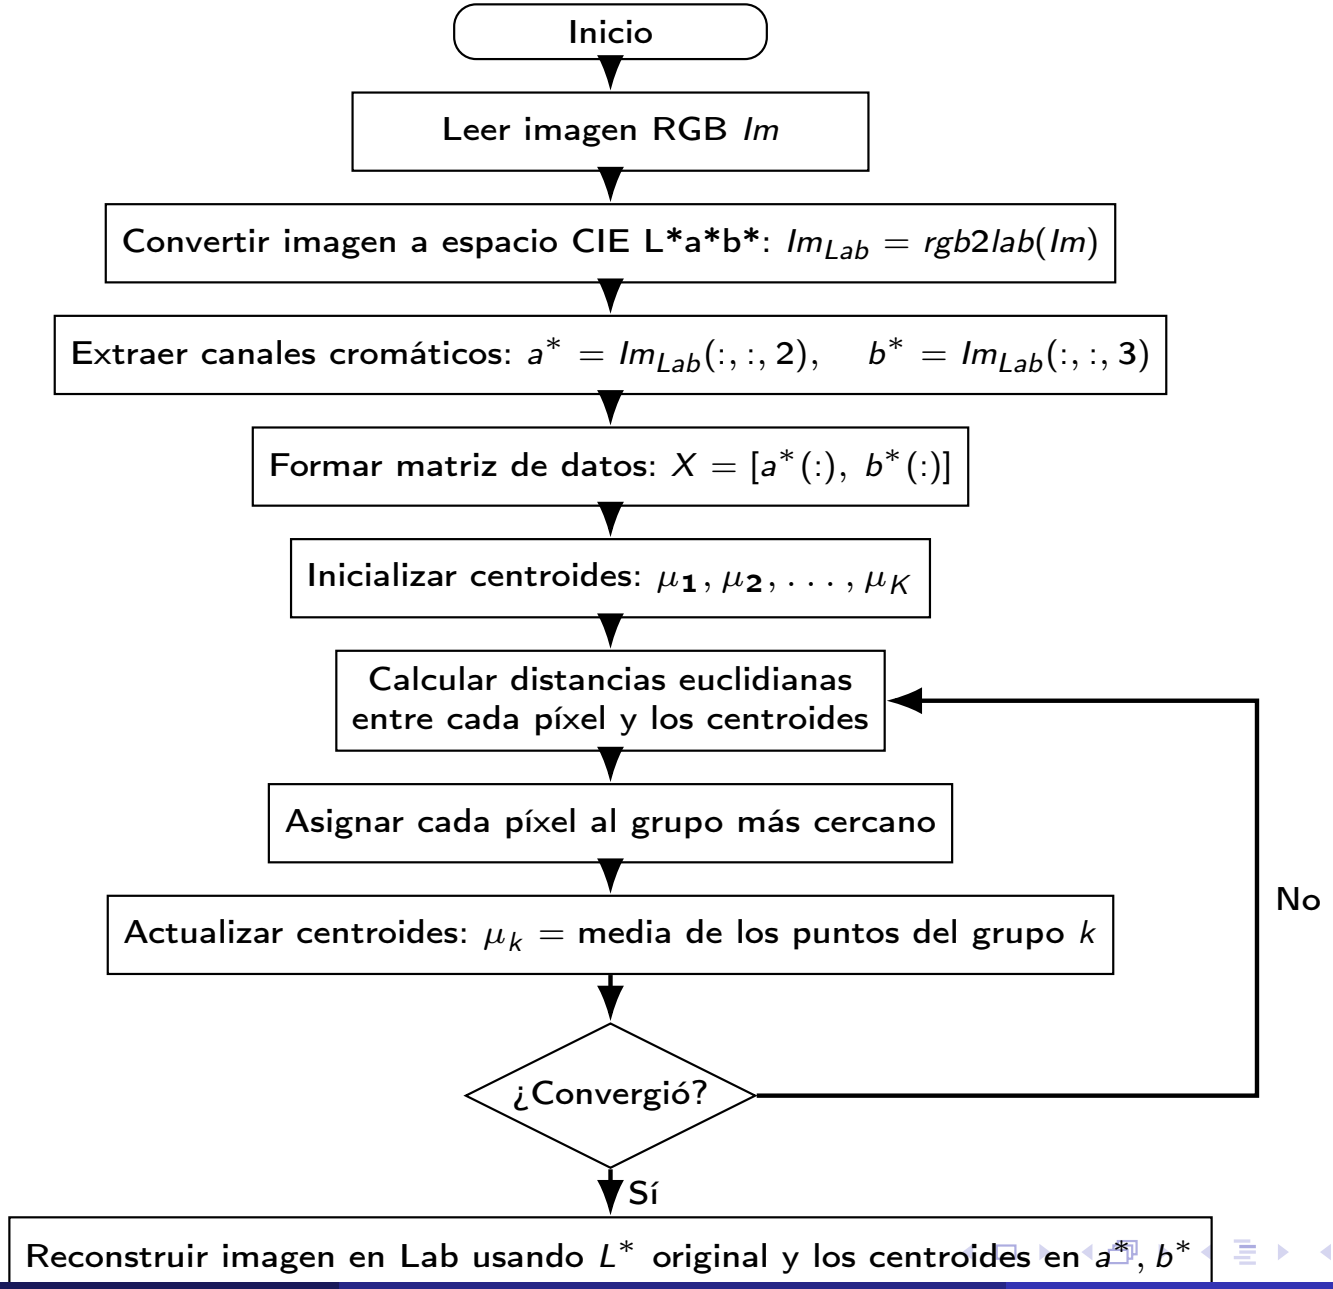

Resultados de K-Means usando CIE L*a*b*

Fácil

F1

Medio

M1

Difícil

D1

F2

M2

D2

Patrones Binarios Locales (LBP)

Los Patrones Binarios Locales describen la **textura** de una región comparando cada píxel central con sus 8 vecinos.

$$LBP(x_c, y_c) = \sum_{p=0}^{P-1} s(g_p - g_c)$$

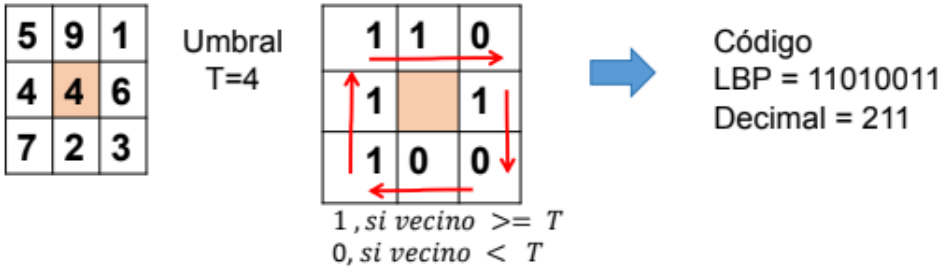

$$s(x) = \begin{cases} 1 & g_p \geq T \\ 0 & g_p < T \end{cases}$$

- g_c: intensidad del píxel central y g_p: intensidad del vecino p.
- El resultado LBP se representa mediante un **histograma normalizado**. Se comparan histogramas de referencia: fuego, humo y vegetación.

$$d(H_1, H_2) = \sum_i \frac{(H_1(i) - H_2(i))^2}{H_1(i) + H_2(i)}$$

- Si la distancia es cercana a 0, las texturas son prácticamente idénticas. Si la distancia es grande, las texturas son diferentes.

Tabla comparativa de resultados

Dificultad	Canny	Otsu simple	Otsu Mult.	KMeans RGB	KMeans CIE L*a*b
Fácil (F1)	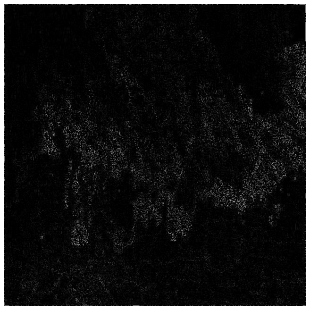		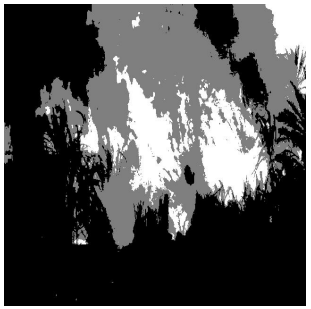		
Medio (M1)	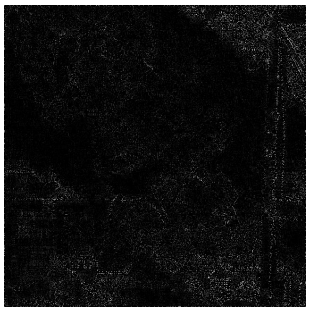		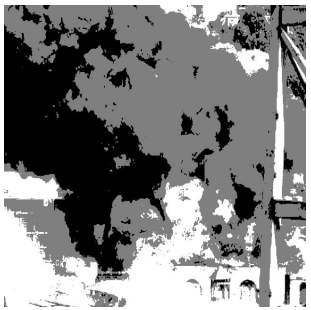	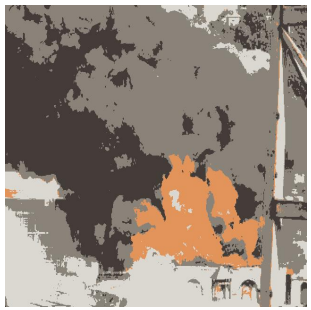	
Difícil (D1)		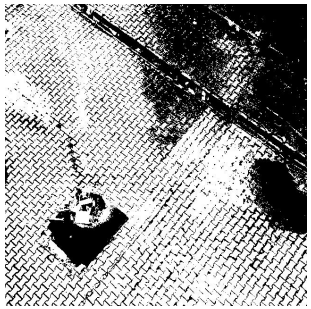			

Conclusiones

- Se implementaron técnicas de segmentación para identificar regiones asociadas a fuego, humo, vegetación y fondo en imágenes con diferente nivel de complejidad.
- Canny permitió resaltar bordes y transiciones de intensidad, pero no fue suficiente para segmentar directamente las zonas de fuego.
- Otsu simple y Otsu multinivel separaron regiones por intensidad, aunque su desempeño fue limitado en imágenes con humo, sombras o fondos complejos.
- K-Means RGB mejoró la segmentación al utilizar información de color; sin embargo, puede confundirse cuando existen objetos con tonalidades similares al fuego.
- K-Means en CIE L*a*b* presentó un mejor comportamiento, ya que separa la luminosidad de la información cromática y facilita la identificación de regiones con fuego.
- En general, los métodos basados en color fueron más adecuados para la segmentación de fuego, especialmente en imágenes de complejidad media y alta.

Referencias

- R. C. Gonzalez y R. E. Woods, *Digital Image Processing*, 4th ed., Pearson, 2018.
- A. K. Jain, *Fundamentals of Digital Image Processing*, Prentice Hall, 1989.
- K. Zuiderveld, "Contrast Limited Adaptive Histogram Equalization," in *Graphics Gems IV*, Academic Press, 1994.
- R. C. Gonzalez y R. E. Woods, "Local Noise Reduction Filters," in *Digital Image Processing*, 4th ed., Pearson, 2018.
- R. H. Hwang and R. A. Haddad, "Adaptive Median Filters: New Algorithms and Results," *IEEE Transactions on Image Processing*, vol. 4, no. 4, pp. 499–502, 1995.